

## Sprawozdanie z listy 2. – Symulacja komputerowa L

Filip Antoniak (279929)

### 1. Wstęp

Celem tego sprawozdania jest stworzenie generatora liczb pseudolosowych dla rozkładu równomiernego  $U[0,1)$  i zbadanie jego właściwości i statystyk.

### 2. Generator ciągów

Aby powstałe ciągi liczb miały rozkład równomierny i spełniały założenie zakresu  $U[0,1)$ , należy zadbać aby wśród liczb nie było wartości 1. Można zrobić to na szereg sposobów, np.:

```
# random [0, 1)
def random_0_1():
    rand = 1
    while rand == 1:
        rand = random.random()
    return rand

def generate_rand_seq(n):
    seq = []
    for _ in range(n):
        seq.append(random_0_1())
    return seq

seq20 = generate_rand_seq(20)
seq100 = generate_rand_seq(100)
```

Rysunek 1: Kod z funkcjami generującymi sekwencje z rozkładu  $U[0, 1)$

Powyższy kod generuje sekwencje kolejno, 20 i 100 liczb z zakresu  $[0, 1)$ .

### 3. Najważniejsze statystyki ciągów:

Tabela 1: Najważniejsze statystyki ciągów 20 i 100 elementowych z rozkładu  $U[0, 1)$  w zestawieniu z rozkładem  $U[a, b)$

Statystyka	20 elementów	100 elementów	Rozkład $U[a, b)$
Średnia	0.5658014284566937	0.5030061965761424	$\frac{1}{2}(a + b)$
Mediana	0.5888990157422684	0.5279573234092918	$\frac{1}{2}(a + b)$
Dominanta	0.011304845366908567	0.0003780852239052	Dowolna wartość $(a, b)$
Wariancja	0.11489991921566682	0.07945409758392864	$\frac{1}{12}(b - a)^2$
Odchylenie standardowe	0.338968905971723	0.2818760322977614	$\sqrt{\frac{1}{12}(b - a)^2}$
Skośność	-0.2353565301636867	0.13687055091429873	0
Kurtoza	1.5032580617009816	1.7406611412588406	$-\frac{6}{5}$
Rozstęp	0.9851399960361277	0.9833333264094991	$b - a$

- Średnia: w miarę wzrostu ilości elementów dąży do  $\frac{1}{2}$ .
- Mediana: tak samo jak średnia, dąży do  $\frac{1}{2}$ .
- Dominanta: jako że każda liczba ma równą szansę na bycie wylosowaną, dominantą może być każda dowolna liczba, więc jest niezdefiniowana.
- Wariancja: obliczana ze wzoru:

$$E[(X - \mu)^2] = \int_a^b \frac{1}{b - a} \left(x - \frac{a + b}{2}\right)^2 dx$$

Mówi o tym jak bardzo wartość zmiennej losowej różni się od średniej.

Więc dla  $U[0, 1)$ , gdy liczba elementów dąży do nieskończoności wariancja wyniesie

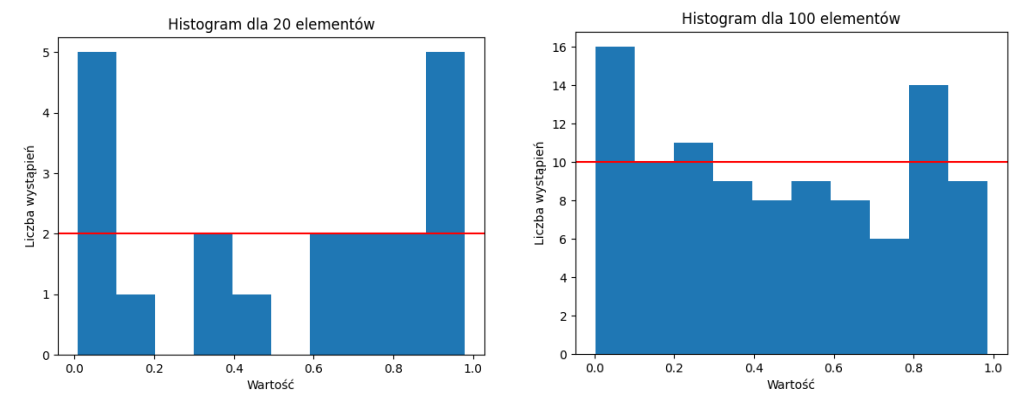
$$\frac{1}{12}(1 - 0)^2 = \frac{1}{12} = 0.08333. \text{ Widać, że dla } U[0, 1) \text{ gdzie liczba elementów osiąga } 100$$

wariancja zbliża się do tej wartości.

- Odchylenie standardowe: Pierwiastek z omówionej wariancji.


- Skośność: Rozkład jest symetryczny więc wartość wynosi 0. Wartości skośności dla 20 i 100 elementów różnią się od 0, ponieważ wielkość sekwencji jest za mała by uzyskać idealny rozkład równomierny.
- Kurtoza: Wartości kurtozy dla sekwencji 20 i 100 elementowych mocno odbiegają od tej dla  $U[a, b)$  wynoszącej  $-\frac{6}{5}$ . Możliwe, że zbieżność osiągana jest później, gdy ilości elementów są większe.
- Rozstęp: będący różnicą wartości maksymalnej przypomina ten oczekiwany już w przypadku 20 elementów.

#### 4. Zestawienie histogramów



Rysunek 2: Histogramy (bins = 10) dla sekwencji 20 i 100 elementowych z rozkładu  $U[0, 1)$ .

Czerwoną linią są oznaczone oczekiwane ilości występowania dla każdej z prób.



Rysunek 3: Funkcja gęstości rozkładu równomiernego  $U[0, 1)$ .

Kształty PDF i histogramów odbiegają od siebie. Wynika to jednak tylko z małej wielkości próby. Zgodnie z prawem wielkich liczb, gdy wielkość próby będzie zbliżała się do nieskończoności, histogram będzie swoim kształtem coraz bardziej przypominał funkcję gęstości prawdopodobieństwa. Różnić się będzie tylko oś Y. W PDF to  $\frac{1}{b-a}$  natomiast w histogramach dla bins=10 wyniesie  $\frac{n}{10}$ , gdzie n to liczba elementów.

## 5. Test statystyczny średnich z prób

$$T = \frac{\bar{X} - \mu_0}{S} \sqrt{n}$$

*ma rozkład t z (n - 1) stopniami swobody.*

### Wymagania testu:

- **Normalność rozkładu:** Dane w każdej z porównywanych grup powinny pochodzić z rozkładów normalnych.
- **Jednorodność wariancji:** Wariancje w obu grupach powinny być do siebie zbliżone.
- **Niezależność obserwacji:** Obserwacje w każdej grupie powinny być niezależne od siebie.

O ile spełnione są założenia 2 i 3, co widać m.in. w tabeli zestawień najważniejszych statystyk, to dane nie pochodzą z rozkładu normalnego.

Z pomocą przychodzi tu CTG, które dla dużych prób (>30), ponieważ rozkład średnich z próby dąży do **rozkładu normalnego**.

**Hipoteza 0:** średnie z prób są równe 0.5

### Wyniki testu:

20 elementów:

t: 0.39626742465189213

p: 0.34816140730017264

**Nie ma podstaw do odrzucenia hipotezy zerowej.**

100 elementów:

t: -1.2640813711441008

p: 0.8954154996305793

**Nie ma podstaw do odrzucenia hipotezy zerowej.**

Dla  $n=20$  nie został spełniony warunek, że dane pochodzą z rozkładu normalnego, tutaj CTG nie pomaga, bo próba  $20 < 30$ . Więc do weryfikacji wykorzystany zostanie dodatkowy test:

Dla testu **Wilcoxon'a**:

Statystyka = 98.0

p-value = 0.8124

wartość p jest znacznie większa niż przyjmowany poziom istotności 0.05, więc **nie ma podstaw co odrzucenia hipotezy zerowej.**

## 6. Wnioski

Testy statystyczne pokazały, że dla prób  $n=20$  i  $n=100$  nie ma podstaw do odrzucenia hipotezy zerowej: *średnia z próby jest równa 0.5*.

Nie było to jednak jednoznaczne dla próby  $n=20$ , w niektórych wywołaniach generowana sekwencja nie przechodziła testu, p value było niższe niż poziom istotności 0.05, więc czasem hipoteza 0 była odrzucana, co oznacza, że średnia była statystycznie istotnie inna niż 0,05.

Wynika to z prawa wielkich liczb, im bardziej zwiększymy wielkość próby w tej symulacji, tym bardziej jej rozkład zbliży się statystycznie do rozkładu równomiernego.

